



Universidad Internacional de La Rioja
Escuela Superior de Ingeniería y Tecnología

Máster Universitario en Análisis y Visualización de Datos
Masivos/ Visual Analytics and Big Data

Valoración inmobiliaria masiva: Econometría Espacial frente a Machine Learning.

Trabajo fin de estudio presentado por:	Adriana Gordillo Calzado y Jesús del Moral Gómez
Tipo de trabajo:	Comparativa de soluciones
Director/a:	Carmen Pérez Gandía
Fecha:	

Resumen

En este apartado se introducirá un breve resumen en español del trabajo realizado (extensión entre 150 y 300 palabras). Este resumen debe incluir el objetivo o propósito de la investigación, la metodología, los resultados y las conclusiones.

El resumen debe contener lo qué se ha pretendido realizar (objetivo o propósito de la investigación), cómo se ha realizado (método o proceso desarrollado) y para qué se ha realizado (resultados y conclusiones).

Importante: En el caso de un TFE grupal, la extensión del TFE debe garantizar que cada uno de los integrantes del equipo ha dedicado a la elaboración y defensa del trabajo las competencias previstas en la memoria. A modo orientativo, y para garantizar la calidad y dedicación que requiere un TFE grupal, la extensión mínima ha de ser un 50% superior a lo previsto para un TFE individual. Por lo tanto, la extensión mínima en un TFE grupal es de **90 páginas**.

Palabras clave: (De 3 a 5 palabras) Descriptores del trabajo que lo enmarcan en unas temáticas determinadas. Serán los utilizados para localizar tu trabajo si llega a ser publicado.

Abstract

En este apartado se introducirá un breve resumen en **inglés** del trabajo realizado (extensión entre 150 y 300 palabras). Este resumen debe incluir el objetivo o propósito de la investigación, la metodología, los resultados y las conclusiones.

Keywords:

Índice de contenidos

1. Introducción	1
1.1. Motivación	1
1.2. Planteamiento del trabajo	2
1.3. Estructura del trabajo	3
2. Contexto y estado del arte	4
2.1. Contexto del problema	4
2.2. Estado del arte	5
2.2.1. Modelos hedónicos y la valoración inmobiliaria	5
2.2.2. Algoritmos de Machine Learning en el sector inmobiliario	8
2.2.3. Feature Engineering Espacial en Machine Learning	12
2.2.3.1 Retardos espaciales (Spatial Lags) como solución a la ceguera espacial	13
2.2.4. Métricas de evaluación	14
2.2.4.1. Índice de Moran de los residuos (Métrica espacial)	16
2.3. Conclusiones	17
3. Objetivos concretos y metodología de trabajo	20
3.1. Objetivo general	20
3.2. Objetivos específicos	20
3.3. Metodología del trabajo	21
4. Marco normativo	24
5. Desarrollo específico de la contribución	27
5.1. Planteamiento de la comparativa	27
5.1.1. Definición del problema empírico y descripción del entorno de datos	27
5.1.2. Identificación de las soluciones alternativas a evaluar	27
5.1.3. Criterios de éxito y métricas de evaluación	27
5.2. Desarrollo de la comparativa	29
5.2.1. Análisis Exploratorio de los Datos (EDA) y preprocesamiento	29
5.2.2. Ingeniería de Datos Espaciales (Spatial Feature Engineering)	29
5.2.3. Regularización y Selección de Variables (LASSO)	29
5.2.4. Diseño experimental y Entrenamiento de Modelos	29
5.2.5. Resultados empíricos de la comparativa	29
5.3. Discusión y análisis de resultados	29
5.3.1. Discusión sobre el rendimiento predictivo y la asimilación espacial	29
5.3.2. Análisis de interpretabilidad mediante Explainable AI (SHAP)	29
5.3.3. Ventajas y desventajas de las soluciones evaluadas	29
6. Código fuente y datos analizados	30

6.1. Código fuente	30
6.2. Datos Analizados	30
7. Conclusiones	31
7.1.	31
8. Limitaciones y prospectiva	32
8.1. Limitaciones	32
8.2. Trabajo futuro	32

Índice de figuras

Figura 2.1. <i>Esquema de funcionamiento de los algoritmos de Bagging y Boosting.</i>	12
--	----

Índice de tablas

Tabla 1. <i>Organización del trabajo en grupo.</i>	10
Tabla 2. <i>Descripción de las variables del dataset de King County.</i>	28

Organización del trabajo en grupo

En este apartado se detallan las distintas partes en las que se ha dividido el trabajo empírico y documental entre los componentes del grupo, garantizando una carga de trabajo equitativa y multidisciplinar. Este Trabajo de Fin de Máster (TFM) se ha desarrollado siguiendo un enfoque de trabajo dinámico y colaborativo, ajustado a los hitos y entregas parciales marcados por el calendario académico. A lo largo de este apartado se detallan los métodos empleados para la división equitativa de responsabilidades —diferenciando el enfoque econométrico del algorítmico—, los objetivos específicos de adquisición de conocimiento y las herramientas de coordinación empleadas para asegurar la cohesión del grupo y la correcta integración de ambas disciplinas

Partes que aborda el TFE

Con el objetivo de asegurar la profundidad analítica, la investigación se ha dividido en cuatro bloques funcionales interdependientes. Cada módulo ha sido concebido con un enfoque metodológico distinto para permitir una alta especialización, hasta el punto de que podrían suponer un Trabajo Fin de Estudios (TFE) independiente. La distribución de las áreas de desarrollo es la siguiente:

Módulo 1: Fundamentación Teórica y Estado del Arte. Este módulo inicial abarca la elaboración de los capítulos introductorios (Capítulos 1, 2 y 3). La tarea principal consiste en una revisión bibliográfica exhaustiva de libros, trabajos académicos y *papers* científicos para establecer un sólido estado del arte, prestando especial atención a la dicotomía histórica entre la econometría espacial clásica y los modelos predictivos de Inteligencia Artificial. El resultado de esta investigación justifica la estrategia metodológica, la necesidad del *Spatial Feature Engineering* y la selección de los algoritmos a evaluar en los módulos subsecuentes.

Módulo 2: Ingeniería de Datos Espaciales y Modelado Estadístico. Este módulo constituye el primer pilar analítico del trabajo. Abarca la fase inicial del ciclo del dato: recolección, limpieza y preprocesamiento del conjunto de datos de viviendas. Su núcleo fundamental es

la creación de variables espaciales (*Feature Engineering*) mediante algoritmos KNN para capturar el efecto del vecindario, así como la implementación, entrenamiento y validación del modelo paramétrico base: el Modelo Hedónico de regresión lineal (SLX).

Módulo 3: Modelado Algorítmico (*Machine Learning*) y Explicabilidad. Este módulo se desarrolla en contraposición analítica al Módulo 2. Su objetivo es la implementación, validación cruzada y optimización de hiperparámetros de los modelos no paramétricos basados en árboles de decisión (Random Forest y XGBoost). Dado el carácter opaco de estos algoritmos (conocidos como "cajas negras"), este módulo requiere una línea de investigación complementaria centrada en la explicabilidad del modelo, utilizando valores SHAP para interpretar el impacto real de las variables espaciales en el precio de la vivienda.

Módulo 4: *Visual Analytics* y Comparativa Espacial de Resultados. Como módulo final, esta parte se centra en la evaluación empírica y la divulgación visual. Comprende el diseño e implementación de soluciones de visualización avanzada, destacando la generación de cartografía interactiva (en formato HTML) para analizar geoespacialmente la distribución de los errores (residuos) de ambos enfoques metodológicos. Este módulo integra el trabajo previo para realizar la comparativa final de rendimiento (RMSE, MAE, R^2), culminando en la extracción de las conclusiones definitivas del proyecto.

Distribución y estructura de la memoria

Aunque el planteamiento estratégico, el diseño metodológico y el abordaje conceptual del proyecto se desarrollan de manera íntegramente conjunta, la primera redacción de los distintos capítulos se distribuye para optimizar los tiempos de trabajo. La Tabla 1 especifica quién asume la responsabilidad principal en la elaboración inicial de cada apartado. No obstante, es fundamental subrayar que **ambos autores colaboran activamente en la edición, corrección y refinamiento de todos y cada uno de los capítulos sin excepción**. Este esfuerzo continuo de coedición resulta indispensable para integrar de forma fluida el rigor econométrico con el enfoque algorítmico del *Machine Learning*, garantizando así la absoluta coherencia y cohesión global del documento definitivo.

Tabla 1. Organización del trabajo en grupo.

Apartado de la memoria	Responsables
Capítulo 1: Introducción	Jesús del Moral
Capítulo 2: Contexto y Estado del arte	Adriana Gordillo
Capítulo 3: Objetivos y Metodología de trabajo	Jesús del Moral
Capítulo 4: Marco normativo	Adriana Gordillo
Capítulo 5: Desarrollo específico de la contribución	Adriana Gordillo y Jesús del Moral
Capítulo 6: Código fuente y datos analizados	Adriana Gordillo y Jesús del Moral
Capítulo 7: Conclusiones	Jesús del Moral
Capítulo 8: Limitaciones y Prospectiva	Adriana Gordillo

Fuente: Elaboración propia.

Objetivo del TFE desde el punto de vista de la adquisición de conocimientos

Desde la perspectiva de la adquisición de conocimientos, este TFM permite a los autores alcanzar una notable multidisciplinariedad, integrando segmentos de investigación que trascienden de lo estrictamente teórico a lo empírico. El carácter grupal del trabajo aporta una visión holística que fusiona la econometría clásica con la inteligencia artificial, confiriéndole una relevancia no solo académica, sino también altamente práctica y aplicable al sector inmobiliario (*PropTech*). Concretamente, se alcanzan las siguientes competencias:

- **Ingeniería de Datos y Tratamiento Espacial (*Spatial Feature Engineering*):** Se adquiere experiencia práctica en la limpieza, transformación y enriquecimiento de datos geoespaciales. Específicamente, se domina la creación de variables espaciales mediante algoritmos de vecinos más próximos (KNN) para capturar y cuantificar el efecto del vecindario (*spillover*) en la valoración de inmuebles.

- **Implementación y Comparativa de Algoritmos Predictivos:** Se desarrolla la capacidad de parametrizar, entrenar y evaluar rigurosamente tanto modelos estadísticos paramétricos (Regresión Hedónica SLX) como algoritmos de aprendizaje supervisado no paramétricos (*Random Forest* y *XGBoost*), dominando la interpretación de métricas de error (RMSE, MAE, R^2) para la extracción de conclusiones.
- **Explicabilidad de Modelos de Inteligencia Artificial:** Se asimila la base teórica y la aplicación práctica de técnicas avanzadas de interpretabilidad, concretamente los valores SHAP (*SHapley Additive exPlanations*), aprendiendo a abrir la "caja negra" del *Machine Learning* para justificar el impacto económico exacto de cada variable en el precio final.
- **Aplicación de *Visual Analytics* para la Comunicación de Resultados:** Se adquiere la capacidad de generar soluciones de visualización avanzada, incluyendo el desarrollo de cartografía interactiva en formato HTML. Esto permite presentar distribuciones de errores espaciales y datos complejos de una manera intuitiva y accesible para audiencias técnicas y de negocio.

Mecanismos de coordinación empleados

La coordinación del equipo se fundamenta en una metodología de trabajo iterativa y colaborativa, estructurando el desarrollo del proyecto en ciclos de revisión semanales. Esta organización permite una adaptación continua, asegurando que tanto el modelado econométrico como la implementación de los algoritmos de *Machine Learning* avancen en paralelo y se alineen perfectamente con los hitos de entrega del TFM.

El principal mecanismo de sincronización son las reuniones de control periódicas, llevadas a cabo mediante videoconferencia a través de Microsoft Team. Estas sesiones de trabajo se estructuran de la siguiente manera:

1. **Revisión de avances:** Se exponen los resultados analíticos obtenidos durante la semana anterior (por ejemplo, la extracción de datos, la creación de variables espaciales o la optimización de hiperparámetros).

2. **Planificación de la siguiente semana:** Tras evaluar el estado global del trabajo, se definen de forma consensuada los objetivos técnicos a corto plazo. Además, se asignan las nuevas responsabilidades y se debaten las estrategias metodológicas para abordar los próximos retos.

De forma complementaria a estas reuniones, se mantiene un canal de comunicación constante a través de WhatsApp, permitiendo la resolución ágil de dudas de redacción o programación y bloqueos técnicos en el día a día. Esta comunicación fluida, sumada a la revisión periódica del progreso y al uso de entornos colaborativos en la nube (GitHub para el código y Google Drive para la memoria), es la clave para integrar con éxito ambas disciplinas estadísticas durante todo el proceso.

1. Introducción

El presente Trabajo Fin de Máster (TFM) se enmarca en el ámbito del análisis avanzado de datos aplicado al sector inmobiliario (*Real Estate*), abordando específicamente el reto de la valoración masiva de inmuebles. A lo largo de este documento se explora el dilema metodológico existente entre la econometría espacial clásica y los algoritmos predictivos modernos. El objetivo central es realizar una comparativa empírica rigurosa entre un modelo hedónico espacial simplificado (SLX) y técnicas de Machine Learning (Choy & Ho, 2023; Tekouabou et al., 2023), evaluando qué enfoque ofrece el mejor equilibrio entre precisión predictiva e interpretabilidad. Para ello, el trabajo se estructura a partir de la identificación del problema, el diseño de un entorno experimental justo, la ejecución de los algoritmos sobre el conjunto de datos de King County y la posterior síntesis de resultados. A continuación, se detallan la motivación del estudio, el planteamiento estratégico de la solución propuesta y la estructura organizativa de la memoria.

1.1. Motivación

La valoración inmobiliaria masiva (tasación automática o AVM por sus siglas en inglés) es un proceso analítico crítico (Malpezzi, 2008). A nivel público, es el motor que sustenta la equidad en la recaudación de impuestos sobre bienes inmuebles; a nivel privado, es la base de las tasaciones hipotecarias, la gestión de carteras de inversión y el modelo de negocio de las plataformas PropTech¹ (Deppner et al., 2023). Un ligero margen de error en las predicciones puede traducirse en desviaciones de millones de euros, de ahí que la búsqueda de la precisión analítica sea una prioridad constante.

El problema fundamental de este dominio radica en la naturaleza intrínseca del mercado inmobiliario: el valor de una vivienda no depende únicamente de sus características físicas (Rosen, 1974), sino que está fuertemente condicionado por su ubicación y por el efecto de contagio o "derrame" (spillover²) del vecindario. Clásicamente, la investigación ha abordado

¹ El término *PropTech* (*Property Technology*) hace referencia al conjunto de empresas y plataformas tecnológicas que aplican innovación digital, incluyendo inteligencia artificial y análisis de datos masivos, a los procesos del sector inmobiliario, como la valoración, compraventa o gestión de activos.

² El efecto *spillover* o de desbordamiento espacial describe el fenómeno por el cual las características o el valor de las propiedades vecinas influyen directamente sobre el precio de un inmueble. Es decir, vivir junto a viviendas de alta calidad o en una zona con buenos servicios incrementa el valor del inmueble propio, independientemente de sus atributos físicos.

este problema mediante modelos econométricos espaciales, los cuales ofrecen una excelente explicabilidad causal pero asumen relaciones estrictamente lineales. Paralelamente, la irrupción de la Inteligencia Artificial ha demostrado que los algoritmos como el *Random Forest* (Breiman, 2001) o el *XGBoost* (Chen & Guestrin, 2016) son capaces de capturar patrones. Sin embargo, su adopción se ha visto frenada porque tradicionalmente actúan como "cajas negras" (Hassija et al., 2023) y sufren de "ceguera espacial" (Nikparvar & Thill, 2021), al ignorar por defecto la topología de los datos.

Por tanto, la relevancia de este trabajo reside en la necesidad latente de la comunidad científica y empresarial de conciliar ambos mundos. Resulta indispensable evaluar empíricamente si la ganancia en exactitud predictiva de los modelos algorítmicos compensa la pérdida de transparencia causal frente a los métodos estadísticos puros, aportando así luz a la toma de decisiones basada en datos en el sector inmobiliario.

1.2. Planteamiento del trabajo

El problema o necesidad detectada del que parte este TFM es que, en la literatura actual, las comparativas entre econometría y aprendizaje automático suelen ser asimétricas (Li et al., 2021; Zaki et al., 2022). Frecuentemente, se enfrentan modelos espaciales complejos (que contienen matrices de vecindad) contra modelos de *Machine Learning* puros (que solo ven las características físicas de la casa).

Para solucionar este sesgo, este trabajo propone un enfoque innovador y metodológicamente robusto: simplificar el enfoque econométrico a un modelo hedónico con variables de vecindad (SLX³). De este modo, se consolida un único conjunto de datos tabular en el que la información espacial (los valores promedio de los 15 inmuebles más cercanos) ya está embebida como características precalculadas (*feature engineering* espacial⁴).

El objetivo a grandes rasgos es utilizar esta misma base de datos homogénea para entrenar, por un lado, el modelo estadístico de referencia y, por otro, algoritmos de aprendizaje

³ El modelo SLX (*Spatial Lag of X*) es una especificación econométrica que incorpora el efecto espacial de forma exógena, añadiendo como variables explicativas los promedios ponderados de las características de las propiedades vecinas (*WX*), sin incluir un retardo en la variable dependiente. Esto permite estimar los efectos directos e indirectos del vecindario con estimadores MCO consistentes (Elhorst, 2014).

⁴ El *Spatial Feature Engineering* es el proceso de construir nuevas variables predictoras a partir de la información geográfica del entorno de cada observación —como el promedio de características de los vecinos más cercanos— e incorporarlas como atributos tabulares estándar al modelo de aprendizaje automático (Nikparvar & Thill, 2021).

automático basados en árboles (*Random Forest* y *XGBoost*). A través de este planteamiento, se garantiza un marco de evaluación en igualdad de condiciones, asegurando que si los algoritmos de Inteligencia Artificial superan al modelo clásico, se deba puramente a su capacidad matemática para procesar no linealidades y no a una ventaja en la cantidad de información suministrada.

1.3. Estructura del trabajo

Para abordar los objetivos propuestos de manera secuencial y ordenada, la presente memoria se estructura en los siguientes capítulos:

En el **Capítulo 2 - Contexto y estado del arte**, se revisan las bases teóricas de la teoría de precios hedónicos, el tratamiento espacial en la econometría y el impacto del *Machine Learning* en la valoración masiva, identificando la brecha metodológica actual.

En el **Capítulo 3 - Objetivos concretos y metodología de trabajo**, se definen las metas específicas del proyecto y detalla el diseño experimental siguiendo el marco de referencia estándar de la industria (CRISP-DM).

En el **Capítulo 4 - Marco normativo**, se analiza el contexto ético y legal, prestando especial atención a las normativas de protección de datos (RGPD) en el tratamiento de información inmobiliaria.

En el **Capítulo 5 - Desarrollo específico de la contribución**, constituye el núcleo práctico del proyecto. Se analizan las variables más influyentes en la predicción de precios de mercado de inmuebles. Para ello, se describen paso a paso los modelos teóricos seleccionados para la comparativa, tanto el modelado estadístico (SLX) como el entrenamiento algorítmico (*Random Forest* y *XGBoost*). Posteriormente, se realiza el análisis comparativo de las métricas de rendimiento de cada modelo. Finalmente, se exponen las conclusiones extraídas de los resultados obtenidos.

En el **Capítulo 6 - Código fuente y datos analizados**, se documenta la disponibilidad y el acceso a los *scripts* analíticos y a los conjuntos de datos empleados para garantizar la replicabilidad del estudio.

En el **Capítulo 7 - Conclusiones**, se presentan las conclusiones finales del trabajo, evaluando la eficacia de los métodos empleados y los resultados obtenidos en cada uno de ellos a lo largo del estudio.

Por último, el **Capítulo 8 - Limitaciones y prospectiva** sintetiza los hallazgos principales, se evalúan las barreras encontradas durante el desarrollo del estudio y se proponen futuras líneas de investigación derivadas de este trabajo.

2. Contexto y estado del arte

En este capítulo se establece el marco teórico y contextual sobre el cual se fundamenta el presente Trabajo Fin de Máster. En primer lugar, se describe la problemática actual en el dominio de la valoración inmobiliaria masiva (Sección 2.1), destacando el dilema existente entre la interpretabilidad causal de los modelos econométricos espaciales y la precisión predictiva algorítmica de los enfoques de caja negra. Posteriormente, se realiza una revisión estructurada de la literatura científica y el estado del arte (Sección 2.2), abordando la teoría de precios hedónicos, la evolución de los modelos de Machine Learning en el sector Real Estate, las estrategias recientes de ingeniería de características (*feature engineering*) espacial y las métricas de evaluación más empleadas en la literatura. Finalmente, el capítulo concluye con una síntesis de las evidencias encontradas (Sección 2.3), identificando la brecha metodológica actual que justifica la necesidad de la comparativa experimental propuesta en este documento.

2.1. Contexto del problema

La valoración inmobiliaria masiva es un proceso fundamental tanto para la administración pública (recaudación de impuestos) como para el sector privado (tasaciones hipotecarias, plataformas PropTech). Históricamente, este dominio se ha abordado desde la econometría clásica mediante modelos de precios hedónicos. Sin embargo, el mercado inmobiliario presenta un reto intrínseco: el valor de un inmueble no solo depende de sus características físicas (intrínsecas), sino también de su ubicación y del efecto de "derrame" (spillover) de las propiedades vecinas.

En la actualidad, existe un dilema metodológico. Por un lado, la estadística espacial clásica ofrece una gran interpretabilidad causal, pero asume relaciones lineales rígidas. Por otro lado, la irrupción de la Inteligencia Artificial y los algoritmos de Machine Learning (ML) permiten modelar relaciones no lineales complejas con altísima precisión predictiva, pero tradicionalmente han sufrido de "ceguera espacial" al ignorar la topología del entorno, comportándose como modelos de "caja negra". Este trabajo se enmarca en la necesidad de conciliar ambos mundos, evaluando si la ganancia predictiva del ML justifica la pérdida de interpretabilidad directa frente a modelos econométricos espacialmente explícitos.

2.2. Estado del arte

2.2.1. Modelos hedónicos y la valoración inmobiliaria

La valoración inmobiliaria desde una perspectiva económica encuentra su fundamento en la Teoría de los Precios Hedónicos, formalizada por Rosen (1974), quien extendió las ideas previas de Lancaster (1966) sobre la nueva teoría del consumidor. Bajo este enfoque, la vivienda no se percibe como un bien homogéneo, sino como un "paquete" de atributos o características que generan utilidad para el comprador. En consecuencia, el precio de mercado de un inmueble se entiende como la suma de los precios implícitos de cada uno de sus atributos, tales como la superficie, el número de habitaciones, la calidad de los materiales o su ubicación geográfica.

Matemáticamente, la función de precios hedónicos relaciona el precio observado con sus características estructurales (S), de vecindario (N) y ambientales (Q), expresándose generalmente tal y como se detalla en la Ecuación 2.1:

$$P = f(S, N, Q) \quad (2.1)$$

La determinación de la estructura matemática óptima para esta función ha sido objeto de un intenso debate econométrico. En un estudio seminal, Rasmussen y Zuehlke (1990) evaluaron la idoneidad de distintas formas funcionales, comparando modelos lineales tradicionales con

transformaciones más sofisticadas como la de Box-Cox⁵. Sus hallazgos proporcionan una justificación técnica fundamental para el uso del **logaritmo en la variable dependiente**.

En primer lugar, la especificación log-lineal suele superar al modelo lineal simple en términos de ajuste estadístico y capacidad para manejar la heterocedasticidad intrínseca de los precios inmobiliarios. En segundo lugar, frente a transformaciones como Box-Cox, el logaritmo ofrece resultados similares con una interpretación económica mucho más intuitiva mediante **semi-elasticidades**⁶. Complementariamente, autores como Bax, Zewotir y North (2019) reconocen en su introducción que el uso del logaritmo permite "normalizar" la distribución de los valores de venta, que suelen presentar una fuerte asimetría positiva.

No obstante, la aplicación de modelos de regresión lineal por Mínimos Cuadrados Ordinarios (MCO) en el sector inmobiliario enfrenta un desafío crítico: la dependencia espacial. Dado que las propiedades cercanas suelen compartir características y externalidades similares, se viola el supuesto clásico de independencia de las observaciones (o ausencia de autocorrelación en los residuos), lo que puede sesgar los resultados (Anselin, 1988).

Para corregir esta limitación sin incurrir en la complejidad computacional o los problemas de identificación de modelos de interacción endógena (como el modelo SAR), surge el Modelo de Rezagos Espaciales de Variables X (SLX, siglas en inglés de "Spatial Lag of X "). El modelo SLX aborda el componente espacial mediante la integración de interacciones exógenas⁷. Esto se logra incorporando en la ecuación los rezagos espaciales de las variables explicativas de las propiedades vecinas (denotados como WX). Matemáticamente, se expresa como en la Ecuación 2.2:

$$y = X\beta + WX\theta + \varepsilon, \quad (2.2)$$

⁵ La transformación de Box-Cox, introducida por Box y Cox (1964), es una técnica paramétrica diseñada para determinar la forma funcional óptima de una regresión mediante un parámetro variable. Aunque es más flexible, se suele descartar en modelos hedónicos debido a la dificultad de interpretar los coeficientes resultantes, que dejan de ser elasticidades directas.

⁶ Medida que indica la variación porcentual en el precio ante un cambio unitario en un atributo (por ejemplo, cuánto porcentaje aumenta el precio por cada metro cuadrado adicional), facilitando la comparación entre propiedades de distintos niveles de precio.

⁷ Según Elhorst (2014), las interacciones exógenas ocurren cuando el valor de la variable dependiente de una unidad de observación específica está condicionado por las variables independientes o explicativas de otras unidades vecinas. A diferencia de las interacciones endógenas, aquí el efecto no proviene del resultado (precio), sino de las características externas.

donde y representa el vector de la variable dependiente, en este caso el precio de las viviendas, de tamaño $(n \times 1)$. La matriz de variables explicativas, de tamaño $(n \times k)$, está representada por X y contiene las características intrínsecas de cada observación (m^2 , número de habitaciones, antigüedad, etc.). W corresponde a la matriz de pesos espaciales⁸, es una matriz de $(n \times n)$ que define quién es "vecino" de quién. Esta matriz suele estar normalizada por filas (para que su suma sea igual a la unidad), de modo que cada fila indica la influencia o cercanía de las propiedades adyacentes. El término WX son las variables explicativas rezagadas espacialmente. Es el producto de la matriz de pesos espaciales por las variables independientes y representa el promedio ponderado de las características de los vecinos. Por ejemplo, si X es "metros cuadrados de jardín", WX indica cuántos metros de jardín tienen, de media, las casas de alrededor. Por otra parte, los coeficientes β son los Coeficientes de Efecto Directo, representan el impacto de las variables independientes sobre el precio de la propia vivienda, en otras palabras, indican cuánto varía el precio cuando cambia una característica interna, manteniendo lo demás constante. Asimismo, los coeficientes θ hacen referencia a los Coeficientes de Efecto de Desbordamiento o *Spillover* que miden el impacto de las características de los vecinos sobre el precio del inmueble. Por último, ε representa el vector de errores aleatorios o las variables no observadas que no tienen estructura espacial.

A diferencia de otros modelos espaciales más complejos, el SLX presenta dos ventajas fundamentales para la investigación inmobiliaria según la taxonomía de Elhorst (2014):

1. **Simplicidad Econométrica:** Al no incluir un rezago en la variable dependiente (Wy), el modelo evita problemas de endogeneidad y retroalimentación espacial. Esto permite que los estimadores obtenidos por MCO sean consistentes y eficientes, sin necesidad de recurrir a métodos de máxima verosimilitud.
2. **Interpretabilidad Directa:** La estructura del modelo permite separar claramente los efectos directos (el impacto de las características de la propia casa) de los efectos

⁸ La matriz de pesos espaciales (W) es una estructura matemática que formaliza la configuración geográfica de las observaciones en el modelo. Según Dubin (2009), su función principal es imponer una estructura de dependencia sobre los datos, definiendo de manera exógena qué unidades se consideran "vecinas" y con qué intensidad influyen unas sobre otras.

indirectos o de vecindad (el impacto de las características de las casas vecinas, representadas por el término WX).

Esta configuración soluciona de manera elegante el problema de la omisión de variables espaciales que suele contaminar los modelos hedónicos clásicos (Malpezzi, 2008), ofreciendo una visión más precisa de la formación de precios en el territorio.

2.2.2. Algoritmos de Machine Learning en el sector inmobiliario

En la última década, la valoración inmobiliaria ha experimentado una profunda transformación metodológica gracias a la irrupción del aprendizaje automático (*Machine Learning*). Tal y como señalan Choy y Ho (2023) en su investigación, la aplicación práctica de estas técnicas se ha extendido en los últimos años, experimentando un crecimiento constante y acelerado, demostrando que superan notablemente a las técnicas estadísticas tradicionales. Esta tendencia es corroborada por Tekouabou et al. (2023) en su revisión sistemática sobre predicción inmobiliaria urbana, donde concluyen que, por su alta adaptabilidad a las dinámicas no lineales de los mercados modernos, los algoritmos de Inteligencia Artificial logran frecuentemente una mayor precisión predictiva que los métodos lineales convencionales, aunque todavía enfrentan importantes desafíos de implementación y explicabilidad.

Su principal ventaja radica en la capacidad de procesar volúmenes masivos de datos heterogéneos y, fundamentalmente, en su flexibilidad para modelar relaciones no lineales sin requerir las estrictas hipótesis paramétricas (como la normalidad o la homocedasticidad) que exigen los modelos espaciales tradicionales. Dentro de la predicción y valoración inmobiliaria urbana, un artículo reciente (Tekouabou et al., 2023) señala que los métodos clásicos de *Machine Learning* basados en árboles de decisión y métodos de ensamblaje se han posicionado como los enfoques predominantes, superando a las técnicas de aprendizaje profundo (*Deep Learning*):

- **Árboles de Decisión (Decision Trees)**

Los árboles de decisión, que constituyen la unidad básica de estos algoritmos, operan como modelos predictivos de aprendizaje supervisado que estructuran las relaciones entre las

variables independientes y la variable objetivo a través de una arquitectura jerárquica. En el ámbito de la tasación inmobiliaria, la principal virtud de esta metodología radica en su transparencia. Su mecánica se fundamenta en la creación de ramificaciones lógicas: cada nodo interno establece una regla de partición basada en una característica del inmueble (por ejemplo, superar los 150 metros cuadrados o ubicarse en una determinada zona postal), encauzando los datos hasta llegar a un nodo terminal u "hoja" que emite el valor predictivo final. De este modo, resulta sencillo rastrear el peso de cada atributo en el precio asignado.

Desde una perspectiva matemática, el algoritmo segmenta el espacio muestral de manera recursiva con el objetivo de generar subgrupos cada vez más homogéneos. Al tratarse de un problema de **regresión continua** (predecir el precio de una vivienda), el modelo busca minimizar la varianza interna en cada nodo, utilizando generalmente el promedio de los valores observados en las hojas como estimador final (Loh, 2011). En este proceso, la métrica estándar para evaluar las divisiones es la minimización del Error Cuadrático Medio (MSE). En cada bifurcación, el modelo escruta todas las variables y selecciona aquella que produce la mayor reducción en la varianza del error residual dentro de los conjuntos resultantes.

A pesar de su interpretabilidad, utilizar un único árbol de decisión presenta un obstáculo analítico severo: su altísima sensibilidad al sobreajuste (*overfitting*). Si la profundidad del árbol no se restringe artificialmente, el algoritmo tiende a memorizar el ruido estadístico y las anomalías de la muestra de entrenamiento (Loh, 2011). En un contexto como el mercado inmobiliario, repleto de heterogeneidad espacial y valores atípicos, estas limitaciones de los modelos básicos sobreajustados justifican la transición hacia enfoques de machine learning interpretativamente más robustos, como el Gradient Boosting, que permiten capturar relaciones no lineales sin sacrificar la capacidad de generalización y predicción del precio de inmuebles no observados previamente (Deppner et al., 2023).

Para solventar esta debilidad estructural, la ciencia de datos recurre a las técnicas de ensamblaje (*ensemble*). Estos métodos agrupan múltiples estimadores "débiles" para generar una predicción global mucho más estable y precisa. Dentro de esta categoría, el modelo más extendido es el *Random Forest*.

- **Random Forest**

El *Random Forest* (Bosque Aleatorio) es un algoritmo de ensamblaje que neutraliza la tendencia al sobreajuste (*overfitting*) inherente a los árboles de decisión individuales mediante la construcción simultánea de un "bosque" de múltiples árboles independientes. Para garantizar que estos no generen predicciones idénticas, el algoritmo aplica una doble inyección de aleatoriedad durante su entrenamiento:

1. Cada árbol se entrena utilizando una muestra aleatoria generada con reemplazo a partir del conjunto de datos original, una metodología de ensamblaje conocida como *bagging* (*Bootstrap Aggregating*).
2. En cada punto de división de un nodo, el modelo no evalúa la totalidad de las variables explicativas, sino que se limita a un subconjunto seleccionado al azar.

Este proceso de diversificación asegura que los errores de predicción individuales de cada árbol se compensen entre sí. En el caso de la valoración de propiedades, la estimación definitiva de *Random Forest* se calcula a través del promedio aritmético de las salidas de todos los árboles que componen el modelo. Esta agregación hace que el algoritmo sea altamente robusto frente a los valores atípicos (*outliers*) tan habituales en la distribución de los precios de la vivienda.

Como destacan recientes investigaciones aplicadas al *Real Estate* (Choy & Ho, 2023; Tekouabou et al., 2023), esta agregación reduce drásticamente la varianza predictiva sin incrementar el sesgo. Más allá de su precisión ante relaciones no lineales, la gran ventaja empírica de *Random Forest* para este trabajo es su excepcional tolerancia a la multicolinealidad. Esta propiedad es indispensable, ya que permite introducir en el modelo tanto los atributos intrínsecos de la vivienda como las variables espaciales de los vecinos colindantes —variables que están fuertemente correlacionadas por naturaleza— sin desestabilizar las predicciones.


- **Gradient Boosting y XGBoost**

A diferencia del enfoque en paralelo del *Random Forest*, los métodos de *Boosting* operan de forma secuencial, donde cada nuevo árbol se diseña específicamente para corregir los errores (residuos) del árbol anterior. Recientes investigaciones aplicadas al sector inmobiliario (Deppner et al., 2023; Tekouabou et al., 2023) demuestran que algoritmos

avanzados como XGBoost (*eXtreme Gradient Boosting*) representan el estado del arte en la predicción de valoraciones. De hecho, estudios comparativos directos, como el desarrollado por Zaki et al. (2022), evidencian empíricamente que estas técnicas de aprendizaje automático logran superar sistemáticamente al modelo tradicional de precios hedónicos al no depender de supuestos paramétricos estrictos. Al optimizar una función de pérdida a través del descenso de gradiente, XGBoost consigue identificar los patrones no lineales más sutiles en la formación de los precios, alcanzando niveles de precisión predictiva inalcanzables para la econometría clásica pura.

A pesar de esta contrastada superioridad predictiva, la adopción de estos algoritmos en el ámbito institucional e hipotecario se ha visto históricamente frenada por el problema de la interpretabilidad, al ser considerados modelos opacos o de "caja negra". En este contexto, estudios recientes como el de Deppner et al. (2023) subrayan la necesidad imperativa de adoptar enfoques de *Interpretable Machine Learning* (Aprendizaje Automático Interpretable). Para resolver esta limitación teórica, la literatura reciente sobre Inteligencia Artificial Explicable (XAI, por sus siglas en inglés) destaca la eficacia de metodologías agnósticas como los valores SHAP (*SHapley Additive exPlanations*) (Hassija et al., 2023). Mediante la aplicación de esta técnica, basada en la teoría de juegos, es posible descomponer y cuantificar el impacto marginal exacto de cada variable en la predicción final, garantizando así que la tasación algorítmica esté respaldada por una lógica económica y espacial auditable.

Figura 2.1. Esquema de funcionamiento de los algoritmos de Bagging y Boosting.



Fuente: *Int. J. Environ. Res. Public Health* 2021, 18(16), 8530; <https://doi.org/10.3390/ijerph18168530>

2.2.3. Feature Engineering Espacial en Machine Learning

El principal obstáculo metodológico al aplicar algoritmos genéricos de *Machine Learning* (como *Random Forest* o *XGBoost*) a la valoración inmobiliaria es la denominada "ceguera espacial". Por defecto, estos modelos asumen que cada observación es independiente e idénticamente distribuida (hipótesis i.i.d.), ignorando la Primera Ley de la Geografía de Tobler (1970), la cual postula que las observaciones cercanas están más relacionadas entre sí que las lejanas. Al tratar los datos de vivienda como simples filas aisladas, el algoritmo es incapaz de detectar el vecindario, las distancias o los patrones regionales.

Para mitigar esta limitación estructural, la literatura reciente documentada por Nikparvar y Thill (2021) distingue dos grandes enfoques metodológicos: modificar la función objetivo del algoritmo base para hacerla espacial (estrategia compleja y de alto coste computacional), o bien enriquecer la matriz de observaciones original con nuevas variables espaciales precalculadas, proceso conocido como *Spatial Feature Engineering*.

Este trabajo de fin de máster adopta la segunda estrategia, consolidada actualmente como el estándar en la disciplina. Al alimentar los modelos con covariables espaciales adicionales, es posible aprovechar la potencia no lineal y predictiva de algoritmos como *XGBoost* sin necesidad de alterar su arquitectura interna (Nikparvar & Thill, 2021).

Aunque existen diversas técnicas de codificación espacial (como la inclusión directa de coordenadas de latitud y longitud, el uso de campos de distancia euclídea o el filtrado espacial por autovectores), este estudio se centrará en la generación de **retardos espaciales (*Spatial Lags*)**, por ser la aproximación más rigurosa para establecer una comparativa metodológicamente justa con la econometría clásica (Modelo SLX).

2.2.3.1 Retardos espaciales (*Spatial Lags*) como solución a la ceguera espacial

La técnica de *Spatial Lags* consiste en calcular el valor medio de determinadas variables (ya sea la variable objetivo o covariables como la superficie o calidad constructiva) en el entorno inmediato de cada observación para añadirlo como un nuevo atributo predictor ("*feature*"). En la investigación empírica de este proyecto, este entorno se definirá mediante el algoritmo de los K-vecinos más cercanos (KNN, fijando K=15 vecinos), empleándose estrictamente como un método determinista de búsqueda de vecinos espaciales (*Nearest Neighbor Search*) y no como una técnica predictiva o de agrupamiento (*clustering*). Tal y como destacan Halder et al. (2024) en su reciente revisión exhaustiva, su naturaleza no paramétrica, combinada con su simplicidad y facilidad de implementación, convierten a KNN en la herramienta algorítmica idónea para estructurar esta búsqueda espacial de forma transparente y replicable.

Investigaciones recientes como la de Liu et al. (2022) demuestran que la inclusión de estos retardos espaciales en modelos de aprendizaje automático basados en árboles genera mejoras empíricas incuestionables:

1. **Aumento de la precisión predictiva:** El algoritmo "aprende" a ajustar el precio base de la vivienda en función del nivel socioeconómico o constructivo del vecindario circundante.
2. **Reducción de la autocorrelación espacial en los errores:** Al absorber la estructura espacial a través de estas nuevas variables, los residuos del modelo dejan de estar correlacionados espacialmente. Según Liu et al. (2022), la inclusión de *lags* espaciales en un modelo *Random Forest* es capaz de disminuir el índice de autocorrelación (I de

Moran⁹) de los residuos hasta en un 95%, demostrando que el modelo ha dejado de ser "ciego" a la geografía.

De este modo, el *Spatial Feature Engineering* actúa en este TFM como el puente metodológico definitivo. Al calcular manualmente los retardos espaciales de los 15 vecinos más próximos e inyectarlos en el conjunto de entrenamiento del *Machine Learning*, se garantiza que tanto el enfoque econométrico espacial (SLX) como el algorítmico (XGBoost) compitan en igualdad de condiciones, disponiendo ambos de la misma información sobre la topología de la ciudad.

2.2.4. Métricas de evaluación

Para determinar empíricamente qué marco metodológico, la econometría espacial (Modelo SLX) o el aprendizaje automático no paramétrico (*Random Forest* y XGBoost), ofrece un rendimiento predictivo superior, resulta imprescindible establecer un sistema de evaluación robusto.

Dado que la estimación del valor de la vivienda constituye un problema de regresión continua, el rendimiento de los algoritmos no se evalúa mediante tasas de acierto, sino analizando la magnitud y distribución de sus errores (la diferencia entre el precio de transacción real y el precio predicho por el modelo).

La elección de la métrica adecuada ha sido objeto de un intenso debate en la literatura de modelización. Para garantizar una evaluación rigurosa y exenta de sesgos, la investigación académica contemporánea suele adoptar una perspectiva combinada, empleando las cuatro métricas más consolidadas del sector:

1. Error Absoluto Medio (MAE - *Mean Absolute Error*)

El MAE proporciona la visión más directa e intuitiva del margen de error habitual del modelo. Se define como el promedio aritmético de las diferencias absolutas entre las predicciones y los valores reales, tal como se expresa en la Ecuación 2.3:

⁹ El Índice de Moran es una medida de correlación espacial que evalúa si los valores de una variable en una ubicación se asemejan a los de sus vecinos geográficos. En esencia, funciona como un coeficiente de correlación tradicional, pero aplicado entre una variable y su retardo espacial (el promedio de sus vecinos) definido por la matriz de pesos espaciales.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (2.3)$$

En un influyente estudio sobre evaluación de modelos, Willmott y Matsuura (2005) demostraron empíricamente las ventajas del MAE, argumentando que es la medida más natural y menos ambigua para evaluar el rendimiento medio predictivo. Su principal virtud metodológica es que pondera todos los errores por igual, lo que lo hace altamente interpretable en términos económicos.

2. Error Porcentual Absoluto Medio (MAPE - *Mean Absolute Percentage Error*)

Aunque el MAE cuantifica el error promedio en unidades monetarias, la literatura advierte sobre su limitación intrínseca en mercados con alta varianza de precios como el inmobiliario, ya que no contextualiza el error respecto al valor total del activo. Por ejemplo, una desviación de 15.000 € es crítica al tasar un inmueble de 100.000 € (un 15% de error), pero resulta insignificante al valorar una propiedad de lujo de 1.500.000 € (apenas un 1%). Para corregir esta distorsión de escala, resulta indispensable incorporar el MAPE (Ecuación 2.4), el cual expresa el error en términos relativos (porcentuales):

$$MAPE = 100\% \times \frac{1}{n} \sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{y_i} \quad (2.4)$$

El uso del MAPE como métrica complementaria está ampliamente respaldado por los estándares internacionales de valoración masiva (como los de la *International Association of Assessing Officers*, IAAO), ya que proporciona una medida de rendimiento altamente intuitiva tanto para analistas de datos como para tasadores.

3. Error Cuadrático Medio (RMSE - *Root Mean Square Error*)

Matemáticamente, el RMSE representa la desviación estándar de los residuos y se calcula, como muestra la Ecuación 2.5, realizando la raíz cuadrada del promedio de los errores al cuadrado:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (2.5)$$

Aunque autores como Willmott y Matsuura criticaron su sensibilidad a los *outliers*, Chai y Draxler (2014) refutaron esta postura demostrando que evitar el RMSE sería un error grave. Según estos autores, el RMSE resulta superior cuando la distribución de los errores del modelo se aproxima a una curva gaussiana, y su sensibilidad a los *outliers* es, de hecho, una característica altamente deseable. Al elevar los errores al cuadrado, el RMSE penaliza de forma desproporcionada las grandes desviaciones. En el ámbito de la tasación institucional, esta penalización es crítica: cometer un error gigantesco al valorar una propiedad de lujo conlleva un riesgo mucho mayor que pequeñas desviaciones en decenas de pisos estándar.

4. Coeficiente de Determinación (R^2)

Para no depender exclusivamente de las medidas de error absoluto o cuadrático, la investigación empírica incorpora el coeficiente de determinación para evaluar la bondad de ajuste global. Esta métrica, fácilmente interpretable y ampliamente consolidada, cuantifica la proporción de la varianza total en el precio de la vivienda (variable dependiente) que logra ser explicada por las variables independientes del modelo (ver Ecuación 2.6):

$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2} \quad (2.6)$$

Cuyo rango oscila habitualmente entre 0 y 1 (si toma un valor negativo es indicativo de que el modelo de regresión ha actuado de manera deficiente). Tal y como subrayan Chicco et al. (2021), el coeficiente de determinación es superior al resto de métricas porque evalúa directamente si el algoritmo ha logrado descifrar los patrones subyacentes de los datos (acercándose a 1) o si sus predicciones son equivalentes a predecir simplemente la media muestral (acercándose a 0).

2.2.4.1. Índice de Moran de los residuos (Métrica espacial)

Finalmente, dado que el propósito central de esta comparativa metodológica es evaluar la capacidad de los algoritmos para modelar la topología urbana, las métricas de precisión de precios (RMSE, MAE, MAPE) resultan insuficientes por sí solas. Un modelo predictivo puede ser muy preciso a nivel global, pero seguir cometiendo errores sistemáticos agrupados por barrios (infravalorando constantemente una zona o sobrevalorando otra), lo que indicaría que el algoritmo sigue padeciendo "ceguera espacial".

Para cuantificar y penalizar este fenómeno, se calcula el Índice de Moran sobre los residuos (errores) generados por los modelos. Matemáticamente, el I de Moran global (Ecuación 2.7) se formula de la siguiente manera:

$$I = \frac{n}{S_0} \cdot \frac{\sum_{i=1}^n \sum_{j=1}^n w_{ij} (e_i - \bar{e})(e_j - \bar{e})}{\sum_{i=1}^n (e_i - \bar{e})^2} \quad (2.7)$$

Donde n es el número total de observaciones (en este caso inmuebles), e_i y e_j representan los residuos en las localizaciones i y j , $\bar{e}$ es la media general de los residuos, w_{ij} es el valor de la matriz de pesos espaciales que define la estructura de vecindad entre i y j , y S_0 es la suma de todos los pesos espaciales ($\sum_{i=1}^n \sum_{j=1}^n w_{ij}$). Su valor oscila entre -1 y 1 , donde los valores cercanos a 0 indican una ausencia total de autocorrelación (distribución aleatoria de los errores).

La inclusión de esta métrica espacial se fundamenta directamente en los hallazgos de Liu et al. (2022), quienes establecen el Índice de Moran aplicado a los residuos como el estándar para validar el éxito de cualquier técnica de *Feature Engineering* espacial.

2.3. Conclusiones

A modo de conclusión, de todo el análisis del estado del arte desarrollado en este capítulo se desprende una transición metodológica fundamental en el ámbito de la tasación inmobiliaria. Históricamente, la disciplina ha estado dominada por los modelos de precios hedónicos y la econometría espacial clásica. Estos enfoques ofrecen una interpretabilidad

económica insuperable gracias a sus coeficientes paramétricos, pero exigen al investigador definir estructuras matemáticas rígidas (como el modelo semi-logarítmico) que a menudo no logran capturar la alta complejidad

Frente a esta problemática, el estado del arte actual demuestra el ascenso de los algoritmos de *Machine Learning* basados en árboles de decisión (como *Random Forest* y *XGBoost*). Estos modelos no paramétricos han probado empíricamente su superioridad en la reducción del margen de error (minimización del RMSE y MAE), al aprender automáticamente las interacciones complejas entre los atributos de la vivienda. Sin embargo, la literatura advierte de la existencia de “ceguera espacial”, un defecto ligado a su arquitectura estándar. Al estar desprovistos de matrices de pesos espaciales (W), los algoritmos de IA tienden a agrupar espacialmente sus errores, violando así el principio de independencia y generando una alta autocorrelación en sus residuos (medible a través del Índice de Moran).

Para solventar esta falta, los investigadores apuntan hacia el *Spatial Feature Engineering*. La literatura confirma que la inyección de retardos espaciales calculados mediante algoritmos de búsqueda (como KNN) permite a los modelos de ML reconocer la topología urbana, eliminando la autocorrelación espacial de sus errores sin sacrificar su flexibilidad matemática y permitiendo el uso de herramientas de explicabilidad (*Explainable AI* como SHAP) para interpretar sus decisiones.

Es precisamente en este punto de unión donde el presente Trabajo Fin de Máster (TFM) encuentra su justificación metodológica y su principal aportación innovadora. La revisión de la bibliografía evidencia una brecha significativa en las publicaciones más recientes. Investigaciones como las desarrolladas por Li et al. (2021) y Zaki et al. (2022), han mostrado la comparativa directa entre modelos de precios hedónicos y técnicas de aprendizaje automático (específicamente *XGBoost*). No obstante, ambos estudios omiten por completo la dimensión espacial en su modelización. Evalúan el rendimiento de modelos predictivos que operan bajo una estricta “ceguera espacial”, ya que no integran variables espaciales en la arquitectura de sus algoritmos.

Frecuentemente, esto resulta en comparativas asimétricas o estructuralmente incompletas, donde los algoritmos compiten sin disponer de la información contextual que determina la formación de precios en la realidad urbana. Para superar esto y obtener conclusiones

robustas, es necesario establecer un marco experimental diferente. Este Trabajo de Fin de Máster abordará dicha brecha utilizando el *dataset* inmobiliario de King County, implementando una simetría metodológica rigurosa: se integrarán retardos espaciales en ambos enfoques. Al dotar tanto a la ecuación econométrica (SLX) como al aprendizaje automático (RF y XGBoost + KNN) de la misma información sobre el entorno, el presente estudio garantiza que ambos modelos compitan en igualdad de condiciones para determinar qué modelo es superior en la tasación de inmuebles.

3. Objetivos concretos y metodología de trabajo

Este capítulo constituye el núcleo estratégico del proyecto, actuando como el nexo de unión entre la revisión teórica previa y el desarrollo experimental de la contribución. En las secciones siguientes, se definen los propósitos fundamentales que guían esta investigación, partiendo de un objetivo general centrado en la comparativa de precisión e interpretabilidad entre modelos. Para asegurar la viabilidad del estudio, dicho objetivo se desglosa en metas específicas que cubren desde el tratamiento de datos hasta la evaluación de resultados. Finalmente, se detalla la metodología de trabajo, describiendo de forma secuencial los pasos, instrumentos y procedimientos de análisis necesarios para validar la hipótesis planteada y garantizar la replicabilidad del experimento.

3.1. Objetivo general

Los proyectos de análisis de datos aplicados buscan generar un impacto significativo y medible. En este sentido, el propósito de este trabajo no es únicamente aplicar algoritmos predictivos, sino establecer un marco de decisión empírico que permita optimizar los sistemas de valoración inmobiliaria masiva (tasación automática).

Por tanto, el objetivo general de este Trabajo Fin de Máster es: Evaluar y comparar empíricamente la precisión predictiva y la interpretabilidad entre un modelo econométrico espacial simplificado (SLX) y algoritmos avanzados de Machine Learning (*Random Forest* y *XGBoost*). Este análisis busca demostrar si la capacidad de la Inteligencia Artificial para modelar relaciones complejas y no lineales justifica la pérdida de causalidad estadística frente a los enfoques econométricos clásicos, ofreciendo así resultados observables y aplicables para el sector PropTech y la administración pública.

3.2. Objetivos específicos

Para alcanzar el impacto propuesto en el objetivo general, el proyecto se divide en las siguientes metas específicas analizables por separado:

- **Objetivo Específico 1: Procesamiento de datos e integración espacial.** Preparar y estructurar el dataset de viviendas de King County, asegurando que todas las observaciones contengan tanto las características físicas de la vivienda como los

promedios espaciales de los vecinos más cercanos, garantizando un marco de comparación homogéneo.

- **Objetivo Específico 2: Desarrollo y optimización de modelos predictivos.** Diseñar y entrenar los algoritmos de estimación, abordando tanto un modelo hedónico lineal de referencia (SLX), que proporcione coeficientes interpretables y sirva como línea base de rendimiento analítico, como modelos predictivos avanzados basados en árboles de decisión (*Random Forest* y *XGBoost*), optimizando estos últimos mediante técnicas de validación cruzada (*Cross-Validation*) y búsqueda de hiperparámetros para maximizar su capacidad de generalización.
- **Objetivo Específico 3: Evaluación exhaustiva y comparativa metodológica.** Comparar y cuantificar rigurosamente los resultados obtenidos por ambos enfoques empleando métricas de evaluación adecuadas para interpretar los resultados, como de error estandarizadas (RMSE, MAE) y de bondad de ajuste (R^2). A partir de esto, se sintetizan las ventajas y desventajas empíricas de cada modelo, generando recomendaciones prácticas sobre qué enfoque utilizar dependiendo de si el caso de negocio prioriza la interpretabilidad o la exactitud predictiva.
- **Objetivo Específico 4: Interpretabilidad avanzada y análisis visual-espacial.** Desarrollar una visualización interactiva de las predicciones del modelo empleando técnicas de inteligencia artificial explicable (como los Valores de Shapley) y cartografía dinámica de los residuos. Esta meta busca trascender el análisis estadístico tradicional, permitiendo "abrir la caja negra" de los algoritmos no paramétricos para explorar visualmente cómo el entorno geográfico y las características estructurales impactan en la tasación final de cada inmueble.

3.3. Metodología del trabajo

Para garantizar el rigor, la reproducibilidad y el éxito del análisis comparativo, este proyecto adopta como marco de referencia la metodología CRISP-DM (*Cross-Industry Standard Process for Data Mining*), el estándar más utilizado en proyectos de ciencia de datos aplicados. Aunque el trabajo se centra en un análisis comparativo, las fases iterativas de CRISP-DM se adaptan a las necesidades experimentales del estudio de la siguiente manera:

1. **Comprensión del Negocio (*Business Understanding*):** Definición del problema del "dilema" metodológico en la valoración masiva y establecimiento de los criterios de éxito empírico para la comparativa entre econometría y *Machine Learning*.
2. **Comprensión y Preparación de los Datos (*Data Understanding & Preparation*):** Carga del *dataset* de *King County*, limpieza, tratamiento de valores atípicos e integración de las variables de retardo espacial (matriz de vecindad) necesarias para aislar el efecto espacial y permitir una comparativa justa.
3. **Modelado (*Modeling*):** División del entorno en conjuntos de entrenamiento y prueba (*Train/Test Split*). Posteriormente, estimación del modelo SLX mediante Mínimos Cuadrados Ordinarios (MCO) y entrenamiento de los algoritmos algorítmicos (*Random Forest* y *XGBoost*), ajustando parámetros para evitar el sobreajuste.
4. **Evaluación (*Evaluation*):** Ejecución de predicciones sobre el conjunto de prueba aislado y contraste exhaustivo del rendimiento de los tres modelos utilizando las métricas seleccionadas.
5. **Despliegue (*Deployment*):** En el contexto de este TFM, esta fase se materializa en la redacción de las conclusiones, la discusión de aplicabilidad para el sector inmobiliario y la publicación del código fuente analítico en un repositorio accesible para asegurar la transparencia del experimento.

En cuanto a la metodología de trabajo en equipo, el proyecto se rige por un enfoque colaborativo e interactivo, diseñado para integrar de forma fluida las dos disciplinas objeto de estudio: la econometría espacial y el aprendizaje automático. Para ello, se establece una división funcional de las tareas analíticas, respaldada por un sistema de revisiones cruzadas continuas. La planificación y el seguimiento se estructura en torno a reuniones semanales a través de Microsoft Teams, cuyo propósito principal es fijar los objetivos específicos de cada semana, alinear estrategias y evaluar el progreso conjunto. A nivel técnico, esta coordinación se sustenta en el uso de repositorios de control de versiones (GitHub) para garantizar la reproducibilidad del código y en entornos de coedición documental en la nube. Esta dinámica asegura que ambos investigadores trabajen sobre una base de datos unificada,

manteniendo la absoluta coherencia metodológica a lo largo de todo el ciclo de vida del dato.

4. Marco normativo

El presente Trabajo Fin de Máster (TFM) se desarrolla bajo la estricta observancia del marco legal vigente en materia de privacidad y protección de datos. Específicamente, se rige por lo dispuesto en el Reglamento (UE) 2016/679 del Parlamento Europeo y del Consejo, de 27 de abril de 2016 (Reglamento General de Protección de Datos o RGPD), y en la Ley Orgánica 3/2018, de 5 de diciembre, de Protección de Datos Personales y garantía de los derechos digitales (LOPDGDD).

Aunque la naturaleza puramente técnica y analítica de este proyecto minimiza inherentemente los riesgos asociados a la privacidad, el principio de responsabilidad proactiva exige detallar y documentar el tratamiento de la información utilizada para la comparativa metodológica entre la econometría espacial y los algoritmos de *Machine Learning*.

Naturaleza, tipología y fuente de los datos tratados

Los datos empleados para este estudio proceden de un conjunto de datos público y de libre acceso alojado en la plataforma Kaggle, denominado "*House Sales in King County, USA*". Este *dataset* documenta transacciones inmobiliarias realizadas entre mayo de 2014 y mayo de 2015 en el condado de King (Washington, EE.UU.).

La información recopilada es de carácter estrictamente estructural, geográfico y económico (precio de venta, superficie, número de habitaciones, código postal, latitud y longitud, entre otros). Es imperativo destacar que **no se ha recopilado, tratado ni almacenado ningún dato de carácter personal que identifique de forma directa a personas físicas** (tales como nombres de compradores o vendedores, documentos de identidad, correos electrónicos o datos financieros).

Conforme al apartado I de la Guía sobre privacidad y protección de datos personales de la UNIR (Mitigación de Riesgos), los datos empleados tienen la consideración de **datos anonimizados** respecto a los individuos. Si bien la inclusión de coordenadas geográficas exactas (latitud y longitud) podría permitir una identificación indirecta de los propietarios mediante el cruce de datos con registros públicos de la propiedad, en el contexto de este

estudio dichas coordenadas se utilizan exclusivamente para el cálculo de distancias y retardos espaciales (matrices topológicas), operando sobre el activo inmobiliario y no sobre el individuo. No se tratan, en ningún caso, categorías especiales de datos (art. 9.2 del RGPD).

Finalidades, base de legitimación y operaciones de tratamiento

El tratamiento de los datos responde a una finalidad exclusiva y estrictamente académica e investigadora: el análisis de la formación de precios en el mercado inmobiliario urbano y la evaluación comparativa de modelos predictivos.

En cuanto a la base de legitimación (Art. 6.1 del RGPD), el tratamiento se ampara en el **interés legítimo** del investigador para fines de investigación científica y estadística (Art. 89 del RGPD), ponderado frente a la nula injerencia en los derechos y libertades de los ciudadanos, dado el carácter público e indirecto de la información.

Las operaciones de tratamiento se limitan estrictamente a:

- Descarga de la base de datos desde el repositorio público (Kaggle).
- Limpieza, transformación y estandarización de variables (Análisis Exploratorio de Datos).
- Creación de variables de ingeniería espacial (Cálculo de *Spatial Lags* mediante algoritmos KNN).
- Entrenamiento de modelos predictivos (SLX, *Random Forest*, XGBoost) y evaluación de sus residuos.

Principios de protección de datos aplicables

Para garantizar la diligencia en el tratamiento, este TFM se ajusta a los siguientes principios (Art. 5 RGPD):

- **Licitud y transparencia:** Los datos provienen de fuentes abiertas y documentadas.
- **Minimización de datos:** Se han utilizado únicamente las variables estrictamente necesarias para la modelización espacial, descartando cualquier campo del repositorio original que no aportara valor predictivo al estudio.

- **Limitación del plazo de conservación:** El conjunto de datos será conservado en los equipos del investigador exclusivamente durante el tiempo necesario para la elaboración, defensa y evaluación del presente Trabajo de Fin de Máster. Una vez finalizado el proceso académico, los archivos locales que contengan los datos brutos serán eliminados de forma segura.

Medidas de seguridad y cumplimiento normativo

Dado que el tratamiento no supone un riesgo para los derechos y libertades de las personas físicas (al tratar características de bienes inmuebles anonimizados), **no resulta preceptiva la realización de una Evaluación de Impacto** sobre la Protección de Datos (EIPD). No obstante, se han aplicado las siguientes medidas técnicas y organizativas para garantizar la seguridad de la información:

1. **Almacenamiento seguro:** El procesamiento de los datos se ha realizado de forma local en equipos protegidos mediante contraseñas de acceso seguro y software antivirus actualizado.
2. **Ausencia de cesiones y transferencias:** Los datos no han sido cedidos a terceros, ni se ha proporcionado acceso por cuenta de terceros, ni se ha realizado explotación comercial alguna. No existen transferencias internacionales de datos derivadas de este TFM.
3. **Control de brechas de seguridad:** En el supuesto improbable de una vulneración de los sistemas locales de almacenamiento, el impacto sobre la privacidad sería irrelevante al tratarse de un conjunto de datos público carente de identificadores personales directos.

5. Desarrollo específico de la contribución

5.1. Planteamiento de la comparativa

5.1.1. Definición del problema empírico y descripción del entorno de datos

El problema central que motiva esta comparativa empírica radica en la limitación inherente de los algoritmos de *Machine Learning* tradicionales frente a datos geolocalizados: la denominada “ceguera espacial” de la que venimos advirtiendo a lo largo del TFM. Por defecto, las arquitecturas no paramétricas basadas en árboles de decisión procesan la información de manera tabular, asumiendo que cada observación es independiente del resto. En el ámbito de la tasación inmobiliaria, este enfoque choca frontalmente con la Primera Ley de la Geografía de Tobler, ya que omite el efecto contagio o *spillover* que ejerce el vecindario sobre un activo. Si un algoritmo desconoce la posición topológica de una vivienda respecto a las demás, sus predicciones generarán residuos espacialmente autocorrelacionados, invalidando la robustez del modelo. Por consiguiente, el reto consiste en evaluar si la inyección exógena de información espacial permite a estos algoritmos superar dicha “ceguera” y competir estadísticamente contra modelos que sí integran la geografía en su diseño base (econometría espacial).

Para abordar este problema y ejecutar la comparativa metodológica, se utiliza el conjunto de datos público “*House Sales in King County, USA*”. Este *dataset*, ampliamente reconocido en la literatura de ciencia de datos, documenta las transacciones inmobiliarias de carácter residencial registradas entre mayo de 2014 y mayo de 2015 en el condado de King (Estado de Washington, EE. UU.), zona que engloba la ciudad de Seattle y su área metropolitana. La elección de este entorno de datos no es casual, puesto que King County presenta un mercado inmobiliario altamente dinámico, con una gran heterogeneidad de precios, tipologías constructivas y una marcada segregación espacial, lo que lo convierte en un escenario ideal para poner a prueba la modelización.

El conjunto de datos original consta de 21.613 observaciones y proporciona una visión detallada de cada transacción. Para estructurar el análisis, las variables disponibles se clasifican en cuatro dimensiones fundamentales, tal y como se detalla en la Tabla 2:

Tabla 2. Descripción de las variables del dataset de King County.

Dimensión	Variable	Descripción	Tipo de dato
Objetivo (Target)	price	Precio final de venta del inmueble (Variable dependiente).	Numérico continuo
Geolocalización	lat	Latitud de la propiedad.	Coordenada
	long	Longitud de la propiedad.	Coordenada
	zipcode	Código postal de ubicación del inmueble.	Categorico / Espacial
Características Estructurales	bedrooms	Número de dormitorios.	Numérico discreto
	bathrooms	Número de baños (incluye medios baños).	Numérico continuo
	sqft_living	Superficie habitable de la vivienda (en pies cuadrados).	Numérico continuo
	sqft_lot	Superficie total de la parcela.	Numérico continuo
	floors	Número de plantas de la edificación.	Numérico discreto
	sqft_above	Superficie habitable sobre rasante.	Numérico continuo
	sqft_basement	Superficie del sótano (si existe).	Numérico continuo
Calidad y Conservación	condition	Índice del estado de conservación de la vivienda (escala 1-5).	Categorico ordinal
	grade	Índice de calidad de diseño y construcción (escala 1-13).	Categorico ordinal
	yr_built	Año original de construcción.	Numérico discreto
	yr_renovated	Año de la última	Numérico discreto

		reforma integral (0 si no existe).	
	waterfront	Variable binaria: la propiedad tiene vistas al agua (0 = No, 1 = Sí).	Dicotómica
	view	Calidad de las vistas de la propiedad (escala 0-4).	Categorico ordinal

Fuente: Elaboración propia.

El conjunto de datos original incluye dos variables precalculadas referentes al entorno (`sqft_living15` y `sqft_lot15`), que representan el promedio de superficie (habitable y de parcela, respectivamente) de los 15 vecinos más cercanos. Si bien estas variables suponen un primer acercamiento algorítmico al entorno, en este trabajo se utilizarán las coordenadas espaciales exactas (`lat` y `long`) como base para aplicar algoritmos KNN y generar una matriz de retardos espaciales mucho más profunda, exhaustiva y aplicable al resto de características estructurales.

5.1.2. Identificación de las soluciones alternativas a evaluar

5.1.3. Criterios de éxito y métricas de evaluación

Una vez establecido el marco teórico de evaluación en el apartado del Estado del Arte, resulta imperativo definir los criterios exactos bajo los cuales se juzgará el rendimiento de los modelos desarrollados en este Trabajo Fin de Máster. Para garantizar una comparativa justa y exhaustiva entre el enfoque econométrico (SLX) y los algoritmos de *Machine Learning* (*Random Forest* y *XGBoost*) aplicados al *dataset* de King County, este TFM adopta un sistema de evaluación multidimensional basado en las siguientes decisiones metodológicas:

- **Evaluación del error promedio (MAE y MAPE):** Se decide utilizar el Error Absoluto Medio (MAE) como métrica base de interpretabilidad. Sus resultados se expresarán directamente en la unidad monetaria de la variable objetivo (dólares o logaritmo del precio), lo que indicará exactamente cuánto se desvía, en promedio, cada tasación algorítmica respecto al mercado real. Para complementar esta lectura y evitar distorsiones de escala entre propiedades modestas y de lujo, se incorpora el MAPE,

garantizando así la contextualización porcentual del error exigida por los estándares internacionales de tasación.

- **Penalización de desviaciones extremas (RMSE):** Se adopta el Error Cuadrático Medio (RMSE) con el propósito explícito de penalizar de forma desproporcionada los errores de gran magnitud. En el contexto de este estudio, cometer un error gigantesco al valorar una propiedad de alta gama en King County conlleva un riesgo analítico inaceptable, por lo que el algoritmo que logre minimizar el RMSE demostrará una mayor robustez frente a valores atípicos (*outliers*).
- **Bondad de ajuste global (R^2):** Frente a las métricas de error absoluto, se selecciona el coeficiente de determinación para evaluar la capacidad de los modelos para descifrar la dinámica real de fijación de precios inmobiliarios. El algoritmo que maximice este valor será declarado empíricamente superior en su capacidad de aprendizaje estructural.
- **Evaluación de la topología urbana (Índice de Moran de los residuos):** Dado que la aportación central de este TFM es el modelado espacial, las métricas de precisión convencionales resultan insuficientes. Por ello, se establece el cálculo del Índice de Moran sobre los residuos de las predicciones como el "árbitro definitivo" de la comparativa. Esta decisión metodológica permitirá demostrar estadísticamente si la estrategia de *Spatial Feature Engineering* elegida (la inyección de retardos espaciales calculados sobre los 15 vecinos más próximos mediante KNN) logra absorber con éxito la autocorrelación espacial del mercado de King County. Solo si el Índice de Moran de los residuos se aproxima a cero, se podrá concluir que los modelos de ML han superado la "ceguera espacial" y que sus errores se distribuyen como ruido blanco puramente aleatorio, garantizando que ambos enfoques (IA y Econometría) operan con idéntica rigurosidad espacial.

La combinación de estos criterios garantiza que el modelo ganador no solo sea el que prediga el precio con mayor exactitud monetaria, sino también el que mejor comprenda y respete la geografía económica del entorno analizado.

5.2. Desarrollo de la comparativa

5.2.1. Análisis Exploratorio de los Datos (EDA) y preprocesamiento

5.2.2. Ingeniería de Datos Espaciales (*Spatial Feature Engineering*)

5.2.3. Regularización y Selección de Variables (LASSO)

5.2.4. Diseño experimental y Entrenamiento de Modelos

5.2.5. Resultados empíricos de la comparativa

5.3. Discusión y análisis de resultados

5.3.1. Discusión sobre el rendimiento predictivo y la asimilación espacial

5.3.2. Análisis de interpretabilidad mediante *Explainable AI* (SHAP)

5.3.3. Ventajas y desventajas de las soluciones evaluadas

6. Código fuente y datos analizados

6.1. Código fuente

Es recomendable que el estudiante incluya en su memoria la URL del repositorio donde tiene alojado el código fuente desarrollado durante el TFE. El estudiante debe ser el único autor del código y único propietario del repositorio. En el repositorio no debe haber commit de ningún otro usuario del repositorio

6.2. Datos Analizados

De igual forma, los datos que hayan utilizado para el análisis, siempre que así se considere oportuno, también deberían estar alojados en el mismo repositorio.

Si el TFE está asociado a una actividad o proyecto de Empresa, se debe justificar en la memoria que, por temas de confidencialidad, no se deja disponible ni el código fuente ni los datos utilizados.

7. Conclusiones

Este último apartado es habitual en todos los tipos de trabajos y presenta el resumen final de tu trabajo y debe servir para informar del alcance y relevancia de tu aportación.

Suele estructurarse empezando con un resumen del problema tratado, de cómo se ha abordado y de por qué la solución sería válida.

Es recomendable que incluya también un resumen de las contribuciones del trabajo, en el que relaciones las contribuciones y los resultados obtenidos con los objetivos que habías planteado para el trabajo, discutiendo hasta qué punto has conseguido resolver los objetivos planteados. Las conclusiones ofrecidas deberán ser consecuencia del trabajo realizado y, por lo tanto, deberán marcar el grado de consecución de los objetivos propuestos (cada objetivo del trabajo se enlazará con una conclusión).

7.1.

8. Limitaciones y prospectiva

8.1.Limitaciones

Una vez concluido el trabajo, deberás hacer una **valoración crítica sobre el mismo y exponer las limitaciones que has encontrado** y que han marcado la realización de tu trabajo. Aquí se deberán hacer las consideraciones pertinentes sobre qué problemas o carencias se ha encontrado el autor para el desarrollo del trabajo (necesidad de valorar otras variables, ampliar la muestra, utilizar otros instrumentos, etc.); estas serán las limitaciones del trabajo

8.2.Trabajo futuro

Finalmente, se suele dedicar un último apartado a hablar de líneas de trabajo futuro que podrían aportar valor añadido al trabajo realizado. La sección debería señalar las perspectivas de futuro que abre el trabajo desarrollado para el campo de estudio definido. En el fondo, debes justificar de qué modo puede emplearse la aportación que has desarrollado y en qué campos.

Referencias bibliográficas

- Anselin, L. (1988) Spatial Econometrics: Methods and Models. Kluwer Academic, Dordrecht.
<https://doi.org/10.1007/978-94-015-7799-1>.
- Bax, D., Zewotir, T., & North, D. (2019). A gamma generalised linear model as an alternative to log linear real estate price functions. *Journal of Economic and Financial Sciences*, 12, 11.
<https://doi.org/10.4102/jef.v12i1.476>.
- Box, G., & Cox, D. (1964). An Analysis of Transformations. *Journal of the royal statistical society series b-methodological*, 26, 211-243.
<https://doi.org/10.1111/j.2517-6161.1964.tb00553.x>.
- Breiman, L. (2001). Random Forests. *Machine Learning*, 45(5), 5–32.
<https://doi.org/10.1023/A:1010933404324>
- Chai, T., & Draxler, R. (2014). Root mean square error (RMSE) or mean absolute error (MAE)? – Arguments against avoiding RMSE in the literature. *Geoscientific Model Development*, 7, 1247-1250. <https://doi.org/10.5194/gmd-7-1247-2014>.
- Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794. <https://doi.org/10.1145/2939672.2939785>
- Chicco, D., Warrens, M., & Jurman, G. (2021). The coefficient of determination R-squared is more informative than SMAPE, MAE, MAPE, MSE and RMSE in regression analysis evaluation. *PeerJ Computer Science*, 7. <https://doi.org/10.7717/peerj-cs.623>.
- Choy, L., & Ho, W. (2023). The Use of Machine Learning in Real Estate Research. *Land*.
<https://doi.org/10.3390/land12040740>.
- Deppner, J., Von Ahlefeldt-Dehn, B., Beracha, E., & Schaefers, W. (2023). Boosting the Accuracy of Commercial Real Estate Appraisals: An Interpretable Machine Learning Approach. *The Journal of Real Estate Finance and Economics*, 1 - 38.
<https://doi.org/10.1007/s11146-023-09944-1>.

- Dubin, R. (2009). Spatial weights. In A. S. Fotheringham, P. A. Rogerson (Eds.) *Spatial weights* (pp. 125-158). SAGE Publications Ltd, <https://doi.org/10.4135/9780857020130.n8>.
- Elhorst, J.P. (2014) *Spatial Econometrics: from Cross-Sectional Data to Spatial Panels*. Springer, Heidelberg, Vol. 479, 480. <https://doi.org/10.1007/978-3-642-40340-8>.
- Halder, R., Uddin, M., Uddin, M., Aryal, S., & Khraisat, A. (2024). Enhancing K-nearest neighbor algorithm: a comprehensive review and performance analysis of modifications. *Journal of Big Data*, 11. <https://doi.org/10.1186/s40537-024-00973-y>.
- Hassija, V., Chamola, V., Mahapatra, A., Singal, A., Goel, D., Huang, K., Scardapane, S., Spinelli, I., Mahmud, M., & Hussain, A. (2023). Interpreting Black-Box Models: A Review on Explainable Artificial Intelligence. *Cognitive Computation*, 16, 45-74. <https://doi.org/10.1007/s12559-023-10179-8>.
- Lancaster, K. (1966). *A New Approach to Consumer Theory* (Vol. 74, pp. 132–157). Springer, Berlin, Heidelberg. https://doi.org/10.1007/978-3-642-51565-1_34.
- Li, S., Jiang, Y., Ke, S., Nie, K., & Wu, C. (2021). Understanding the Effects of Influential Factors on Housing Prices by Combining Extreme Gradient Boosting and a Hedonic Price Model (XGBoost-HPM). *Land*, 10(5), 533. <https://doi.org/10.3390/land10050533>
- Liu, X., Kounadi, O., & Zurita-Milla, R. (2022). Incorporating Spatial Autocorrelation in Machine Learning Models Using Spatial Lag and Eigenvector Spatial Filtering Features. *ISPRS Int. J. Geo Inf.*, 11, 242. <https://doi.org/10.3390/ijgi11040242>.
- Loh, W. (2011). Classification and regression trees. *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery*, 1. <https://doi.org/10.1002/widm.8>.
- Malpezzi, S. (2008). Hedonic Pricing Models: A Selective and Applied Review. , 67-89. <https://doi.org/10.1002/9780470690680.ch5>.
- Nikparvar, B., & Thill, J. (2021). Machine Learning of Spatial Data. *ISPRS Int. J. Geo Inf.*, 10, 600. <https://doi.org/10.3390/ijgi10090600>.

Rasmussen, D. W., & Zuehlke, T. W. (1990). On the choice of functional form for hedonic price functions. *Applied Economics*, 22(4), 431–438. <https://doi.org/10.1080/000368490000000002>.

Rosen, S. (1974). Hedonic Prices and Implicit Markets: Product Differentiation in Pure Competition. *Journal of Political Economy*, 82(1), 34–55. <http://www.jstor.org/stable/1830899>.

Tekouabou, S., Gherghina, Ș., Kameni, E., Filali, Y., & Gartoumi, K. (2023). AI-Based on Machine Learning Methods for Urban Real Estate Prediction: A Systematic Survey. *Archives of Computational Methods in Engineering*, 31, 1079-1095. <https://doi.org/10.1007/s11831-023-10010-5>.

Tobler, W. R. (1970). A computer movie simulating urban growth in the Detroit region. *Economic Geography*, 46(sup1), 234-240. <https://doi.org/10.2307/143141>

Willmott, C., & Matsuura, K. (2005). Advantages of the mean absolute error (MAE) over the root mean square error (RMSE) in assessing average model performance. *Climate Research*, 30, 79-82. <https://doi.org/10.3354/cr030079>.

Zaki, J., Nayyar, A., Dalal, S., & Ali, Z. (2022). House price prediction using hedonic pricing model and machine learning techniques. *Concurrency and Computation: Practice and Experience*, 34. <https://doi.org/10.1002/cpe.7342>.

Anexo A. Privacidad y protección de datos

El presente anexo establece las directrices a seguir por el alumno en la elaboración de su memoria, cuando requiera cumplir con la normativa de privacidad y protección de datos personales. (**ver instrucciones**)